ACA N.º 2 · APRENDIZAJE AUTOMÁTICO

PREDICCIÓN DEL VALOR DE VIVIENDAS MEDIANTE UNA RED NEURONAL PROFUNDA

CUN · Especialización en Inteligencia Artificial · Pilar Ventas — Sector inmobiliario

Anyela María Torres Sánchez · Brandon Andrés Ardila Meta · Edwin Arturo Contreras Padua

RUTA METODOLÓGICA

1. **EDA y gestión SQL** — Comprensión del problema, exploración y base SQLite (tabla *housing*)
2. **Preparación y pipeline** — Partición 80/20 (semilla 42) y estandarización con StandardScaler
3. **Modelado neuronal** — MLP de 3 capas ocultas: 128 → 64 → 32
4. **Evaluación y métricas** — MAE, RMSE, R^2, curvas de pérdida/aprendizaje y residuos
5. **Despliegue** — Aplicación interactiva en Streamlit con 8 variables

1. PROBLEMA Y OBJETIVO

¿Cómo aprender relaciones no lineales entre características socioeconómicas y geográficas para estimar el valor medio de vivienda? Se desarrolla un pipeline neuronal reproducible y una interfaz interactiva para apoyar el análisis.

2. DATASET Y EDA

California Housing (Pace y Barry, 1997; Pedregosa et al., 2011): 20.640 registros, ocho variables predictoras (ingreso medio, antigüedad, habitaciones, dormitorios, población, ocupación, latitud y longitud) y un objetivo continuo (*MedHouseVal*, en unidades de USD 100.000). El notebook genera distribuciones, correlaciones y revisión de calidad: sin nulos ni duplicados.

3. GESTIÓN Y PREPARACIÓN

SQLite almacena la tabla *housing* y permite consultas SQL para verificar los datos. Se reserva 80 % para entrenamiento y 20 % para prueba, con semilla 42. StandardScaler estandariza las entradas dentro del pipeline. No se agrega ruido artificial porque puede crear registros tabulares poco realistas.

4. ARQUITECTURA NEURONAL

MLP profundo de tres capas ocultas: 128 → 64 → 32 neuronas. Activación ReLU, optimizador Adam, regularización L2 y early stopping. Se selecciona MLP por tratarse de datos tabulares; CNN/RNN/Transformer no son necesarios para esta modalidad.

8 entradas → **128 ReLU** → **64 ReLU** → **32 ReLU** → **1 salida**

5. EVALUACIÓN

Métricas adecuadas para regresión: MAE, RMSE y R^2. Se compara con DummyRegressor como línea base. El notebook genera curva de pérdida, curva de aprendizaje (entrenamiento vs. validación), valores reales vs. predichos y análisis de residuos.

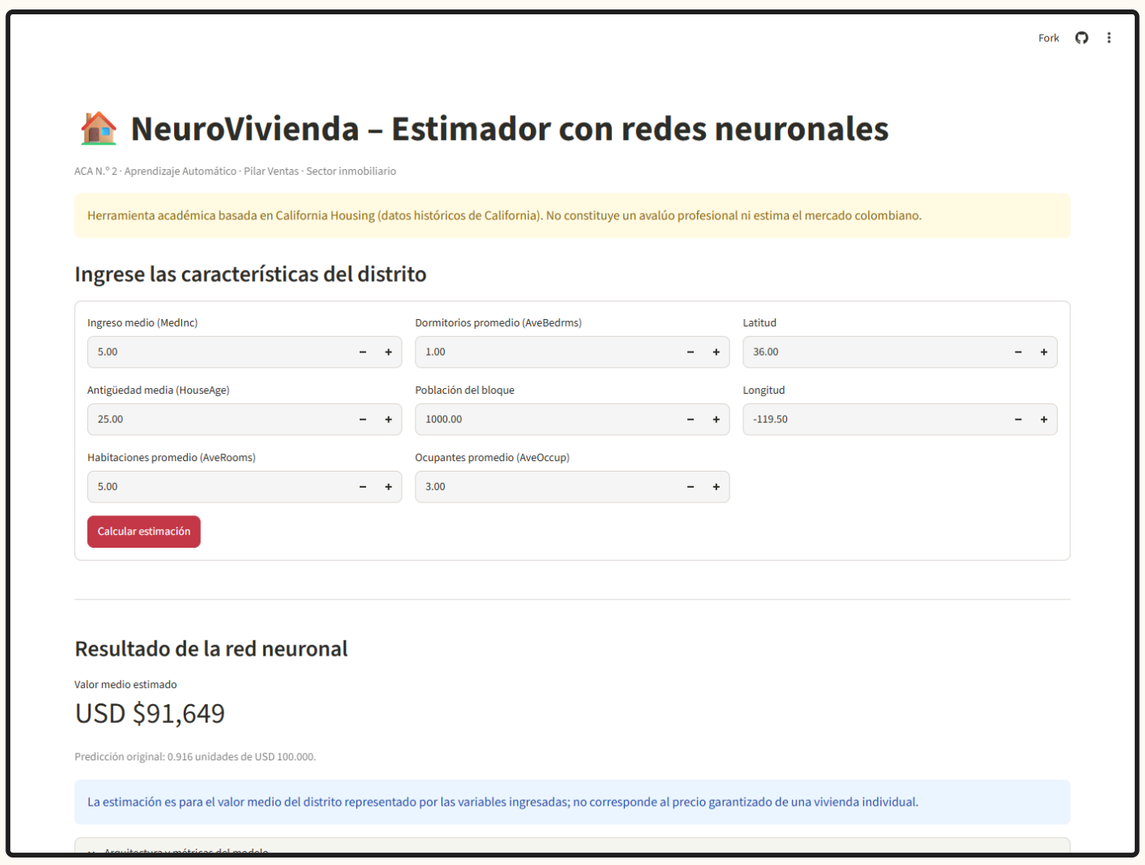
6. RESULTADOS CUANTITATIVOS

Modelo	MAE	RMSE	R^2
MLP 128-64-32	0.349	0.523	0.792
Dummy (media)	0.909	1.149	≈ 0.000

La red explica cerca del 79 % de la variabilidad del valor medio y reduce el error absoluto del Dummy en ≈ 62 %. El MAE equivale a unos USD 34.900. Accuracy, F1 y matriz de confusión no aplican a una variable continua. Valores en unidades de USD 100.000, conjunto de prueba (20 %).

7. DESPLIEGUE

Aplicación publicada en Streamlit Community Cloud: formulario de ocho variables, predicción del valor medio y visualización de arquitectura y métricas (Streamlit, 2026). La captura corresponde a la app en línea calculando una estimación.

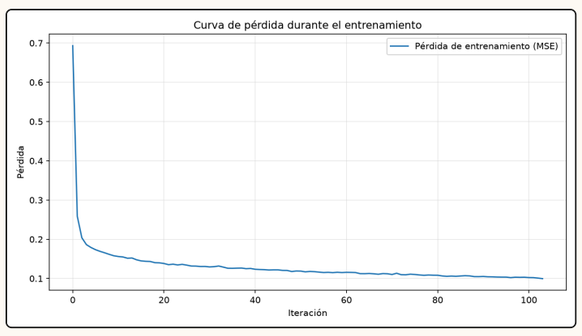


Aplicación publicada: estimación de USD 91.649 con los valores por defecto (captura real).

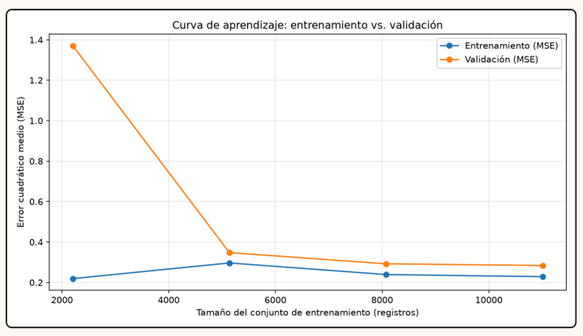
8. CONCLUSIONES Y ALCANCE

El trabajo amplía ACA 1 al sustituir modelos clásicos por una red neuronal profunda. El pipeline integra datos, SQL, entrenamiento, evaluación y despliegue. Los datos son históricos de California: no representan el mercado colombiano ni sustituyen un avalúo profesional.

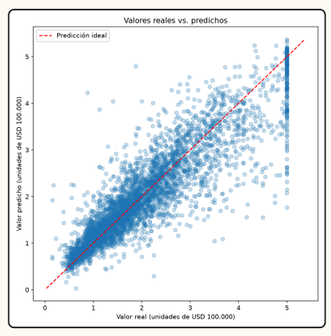
EVIDENCIA GRÁFICA DEL MODELO



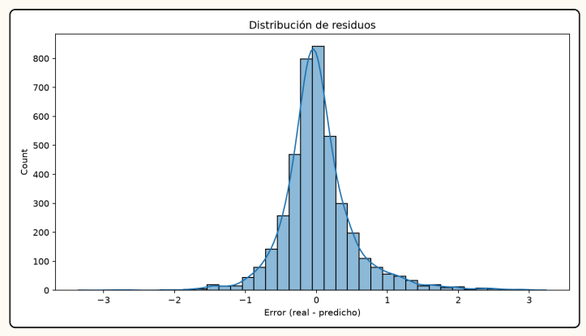
Pérdida de entrenamiento



Curva de aprendizaje (entrenamiento vs. validación)



Valores reales vs. predichos



Distribución de residuos

ENLACES Y REPRODUCIBILIDAD

- Notebook, código y documentación incluidos en el paquete del proyecto. Ejecutar el notebook en orden para generar modelo, métricas y gráficas (semilla 42).
- Aplicación desplegada: **https://aca2-neurovivienda-grupo17.streamlit.app**
- Video de sustentación: https://www.youtube.com/watch?v=FP9k7KeUqiY

REFERENCIAS

Pace, R. K., & Barry, R. (1997). Sparse spatial autoregressions. *Statistics & Probability Letters, 33*(3), 291–297. https://doi.org/10.1016/S0167-7152(96)00140-X

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Streamlit. (2026). *Streamlit documentation*. https://docs.streamlit.io

NOTA: CALIFORNIA HOUSING REPRESENTA DATOS HISTÓRICOS DE CALIFORNIA. LA SALIDA ES UNA ESTIMACIÓN ACADÉMICA DEL VALOR MEDIO DEL DISTRITO, NO UN AVALÚO PROFESIONAL.